

TurtleBot3 ile Pekiştirmeli Öğrenme

Q-Learning ve DQN Karşılaştırmalı Analizi

Faruk

Bilgisayar Mühendisliği

June 25, 2026

Abstract

Bu çalışmada, TurtleBot3 robotunun LIDAR sensörleri kullanarak engellerden kaçınması ve hareketli bir hedefe ulaşması problemi incelenmiştir. İki farklı algoritma olan Q-Learning ve DQN karşılaştırmalı olarak analiz edilmiştir. Q-Learning Testlerde %80.7 başarı oranı ile başarılı sonuçlar elde ederken, DQN ödül fonksiyonunun uygun tasarlanmaması nedeniyle başarısız olmuştur.

1 Giriş

Pekiştirmeli Öğrenme, robotik alanında otonom karar verme problemlerinin çözümünde yaygın olarak kullanılmaktadır. Bu çalışmada, TurtleBot3 robotunun LIDAR verilerini kullanarak hedefe ulaşması problemi ele alınmıştır.

1.1 Problem Tanımı

- Robot: TurtleBot3 (2D simülasyon)
- Sensör: LIDAR (12-24 ışıın)
- Hedef: Hareketli nokta (0.02-0.05 m/s)
- Engeller: Statik duvarlar
- Amaç: Çarpışmadan hedefe ulaşmak

2 Yöntem

2.1 Q-Learning Algoritması

Q-Learning, Bellman Denklemi ile Q-tablosunu güncellenir:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)] \quad (1)$$

2.1.1 State Space

Q-Learning için state diskretize edilmiştir:

Table 1: Q-Learning State Space

Bileşen	Seviye	Açıklama
LIDAR	7x4	7 LIDAR, 4 seviye
Hedef Uzaklık	5	0:yakın, 4:uzak
Hedef Açısı	8	8 farklı yön

Toplam State: $4^7 \times 5 \times 8 = 655.360$ (görülen: 3497)

2.1.2 Action Space

Robot 5 aksiyon alabilir:

Table 2: Aksiyon Uzaı

Aksiyon	Açısal Hız	Anlamı
0	-1.0	Sert Sol
1	-0.5	Hafif Sol
2	0	Düz
3	+0.5	Hafif Sağ
4	+1.0	Sert Sağ

2.1.3 Odul Fonksiyonu

$$R = \begin{cases} -30 & \text{Çarpışma} \\ +100 & \text{Hedef Ulaşma} \\ -20 & \text{Zaman Aşımı} \\ R_{angle} + R_{dist} + R_{obstacle} + 0.05 & \text{Diğer} \end{cases} \quad (2)$$

2.2 DQN Algoritması

DQN, Q-Learning'in derin sinir ağıları ile genişletilmiş halidir:

$$Q(s, a; \theta) \approx Q^*(s, a) \quad (3)$$

2.2.1 DQN State Space

Table 3: DQN State Space

Bileşen	Boyut
LIDAR	12
Hedef Uzaklık	1
Hedef Açısı	1
Hedef Hız	2
Toplam	16

3 Deneysel Sonuçlar

3.1 Q-Learning Sonuçları

3000 episode sonucu:

Table 4: Q-Learning Sonuçları

Metrik	Değer
Başarı	477/3000
Eğitim Başarı Oranı	15.9%
Q-Tablo	3497
Ort. Reward	484.77
En İyi Reward	1046.71

Q-Learning başarılı şekilde öğrenmiştir. Robot, engellerden kaçınmayı ve hedefe ulaşmayı öğrenmiştir.

3.2 DQN Sonuçları

1500 episode sonucu:

Table 5: DQN Sonuçları

Metrik	Değer
Başarı	$\sim 10/1500$
Başarı Oranı	$\sim \mathbf{0.7\%}$
Son Mesafe	4.76m
Test Reward	97.77

DQN başarısız olmuştur. Robot hedefe yaklaşmaktan kaçınmıştır.

4 Tartışma

4.1 Q-Learning Başarısı

Q-Learning başarısının nedenleri:

1. Diskretize state uzayı verimli öğrenme sağlamıştır.
2. Uygun ödül fonksiyonu doğru davranışı teşvik etmiştir.
3. Yeterli keşif ($\varepsilon = 0.998$) ortamın keşfedilmesini sağlamıştır.

4.2 DQN Başarısızlığı

DQN başarısızlığının nedenleri:

1. Yanlış ödül fonksiyonu (hedef yaklaşırken ceza)
2. Yetersiz keşif ($\varepsilon = 0.9995$ çok hızlı azalmış)

3. Hedef çok hızlı (0.05 m/s)
4. Yetersiz eğitim (1500 episode)

4.3 Karşılaştırma

Table 6: Q-Learning vs DQN

Özellik	Q-Learning	DQN
State Tipi	Diskretize	Sürekli
Başarı Oranı	15.9%	0.7%
Hız	Hızlı	Yavaş
GPU	Gerekmez	Gerekir

5 Sonuç ve Öneriler

5.1 Sonuç

- Q-Learning başarılı: %15.9 başarı oranı
- DQN başarısız: Ödül fonksiyonu hatası

5.2 Gelecek Çalışmalar

1. DQN için iyileştirilmiş ödül fonksiyonu
2. Daha yavaş epsilon decay (0.9998)
3. Hedef hızımı düşürmek (0.02 m/s)
4. Daha fazla episode (3000-5000)
5. Double DQN, Dueling DQN denemek

6 Kaynakça

References

- [1] Watkins, C. J. C. H., & Dayan, P. (1992). Q-learning. Machine Learning, 8(3-4), 279-292.
- [2] Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. Nature, 518(7540), 529-533.
- [3] Sutton, R. S., & Barto, A. G. (2018). Reinforcement Learning: An Introduction. MIT Press.
- [4] ROBOTIS. (2024). TurtleBot3 e-Manual.